TECHNICAL REQUIREMENTS DOCUMENT · v1.2

AI 1차 채용면접 자동화 플랫폼 — TRD (기술 요구사항 정의서)

통합 PRD v1.3을 어떻게 만들 것인가

항목	내용
문서명	AI 1차 채용면접 자동화 플랫폼 TRD
문서 유형	Technical Requirements Document
버전 · 작성일	v1.2 · 2026-10-28
기준 PRD	통합 PRD v1.3 (merged_prd_v1.3). 요구사항 ID(ACC-, JOB-, APP-, INT-, QST-, COD-, EVL-, RPT-, ADM-, RES-, CHT-, AC-)는 PRD와 같다
상태	초안(Draft). 6장 모델 배치와 동시 면접 상한 N 초기값은 운영 장비 측정 후 확정
작성 방침	PRD가 정한 '무엇'은 반복하지 않고, 구현 방식·수치·인터페이스만 적는다. 원본 근거 컬럼은 두지 않고 PRD 요구사항 ID로만 연결한다. PRD v1.3부터 구현 값의 기준 문서는 TRD이며, 수치는 14장 설정값 표에 모은다

개정 이력

버전	일자	작성/변경 내용
v1.0	2026-10-28	최초 작성. PRD v1.1과 팀 피드백(AI 합불 판정, 이메일 인증 후순위, VRAM 6GB·RAM 58GB, 질문 재생성 3회, 동시 면접 N, 스캔 이력서 OCR) 기준
v1.1	2026-10-28	PRD v1.2 반영: 질문 재생성 단위·60초 상한·대체 질문·구성 시점 확정, 이의제기·설명 요청 제외. **단일 관리자 기반 전환**: 역할을 applicant/admin 2개로 축소, companies 테이블·company_id·기업 범위 검사 삭제, 데이터 소유권 검증 명시, Open API·더미 공고 적재 추가, 확장 지점 기록(1-3, 1-4)
v1.2	2026-10-28	PRD v1.3 간소화로 넘어온 구현 세부 수용(장애 감지 신호표 7-2, 질문 DB 적재 명세 7-4 ①, 선정 규칙 7-4 ②). TRD_draft 재검토의 빈칸 채움: 하이라이트 구간 산출(8-4), 기준 시간대·건별 공개일·삭제 예정일·관리자 만료 알림 묶음(10장), 로그인 복귀 경로 검증(11장), **설정값 표 신설(14장, 운영 장비·개발 환경 열)**, AC-23 테스트(13-1). 추천안 반영(팀 확인 대기): 동시 면접 상한에서 코딩테스트 단계 제외·'다시 시도'(5-3), 이메일 인증 도입 시 기존 가입자 처리(10장). 표기 정리: 설정 API 경로 /admin

TRD란? (안내) TRD는 PRD의 요구사항을 "어떻게 만드는가"를 정의한다. 아키텍처, 기술 스택, 데이터·API 설계, AI 파이프라인, 성능·보안 구현, 테스트 방법을 다룬다. 사용자 관점의 요구사항이 바뀌면 PRD를 먼저 고치고 TRD를 따라 고친다.

목차

1. 개요와 설계 원칙
2. 시스템 아키텍처
3. 기술 스택
4. 데이터 설계
5. API·실시간 인터페이스
6. 운영 장비와 AI 모델 배치
7. 면접 세션·질문 구성·이력서 OCR
8. 평가·1차 합불 판정 파이프라인
9. 코딩테스트 실행 환경
10. 결과 공개·알림·배치 작업
11. 보안·개인정보
12. 성능 목표와 측정
13. 테스트 계획
14. 설정값 표 · 15. 확인 필요 사항 · 부록 PRD 추적표

1. 개요와 설계 원칙

1-1. 목적과 범위

PRD v1.3의 1차 면접 자동화(공고·평가 기준 설정 → 지원·사전 준비 → AI 면접 → 코딩테스트 → AI 평가·1차 합불 판정 → 결과 공개 → 자동 삭제)를 서버 1대(VRAM 6GB · RAM 58GB) 온프레미스 환경에서 구현하기 위한 기술 기준을 정한다. 2차 전형, 외부 연동, 모바일 앱은 범위 밖이다(PRD 2-2).

1-2. 설계 원칙

원칙	구현 방침	PRD
AI가 판정, 시스템이 검증	LLM이 항목 점수와 1차 합불 판정·사유를 정해진 JSON으로 낸다. 서버 코드는 스키마·점수 범위·인용 원문 일치·'총점 ≥ 합격 기준' 일관성을 검증하고, 통과한 판정만 확정한다. 관리자 API에는 판정 변경 엔드포인트가 없다	1-3 ①②, EVL-05
계산은 코드로	항목 점수·AI 면접 점수·종합 총점은 서버가 Decimal로 계산해 LLM 판정의 입력과 검증에 쓴다. LLM 산술 결과는 신뢰하지 않는다	EVL-03~04
실시간 경로는 GPU 안에서	면접 진행 중 호출(질문 맥락화·범위 조정·꼬리질문 판단·STT)은 GPU 전용 메모리에 올린 모델로만 처리한다. 사후 작업(최종 평가·리포트·임베딩)은 RAM에서 처리할 수 있다	10-1, 10-3
실패해도 멈추지 않는다	질문 생성은 3회 재생성 후 DB·예비 질문으로 대체, TTS 실패는 자막, 분석 실패는 재시도 후 '확인 필요'. 면접 흐름을 막는 실패는 장애 판정(RES)으로만 처리한다	QST-05, INT-01, EVL-08
데이터는 내부에, 짧게	외부 AI API 호출 없음. 모델 파일은 내부 저장소에서 배포. 보관 기간이 지난 데이터는 매일 배치로 원본·파생 데이터까지 삭제	1-3 ④, 10-2
설정값은 코드 밖으로	동시 면접 상한 N, 재시도 횟수, 타임아웃, 이메일 인증 사용 여부 등은 운영 설정(DB 설정 테이블 + Redis 캐시)으로 두고 재시작 없이 바꾼다	INT-08, ACC-02

1-3. 범위 제약: 단일 관리자 기반 (v1.1)

이 프로젝트는 **단일 관리자 기반**이며 실제 기업별 계정이나 멀티테넌시를 지원하지 않는다. 관리자 계정은 하나로 운영하고, 채용공고는 관리자 직접 등록 또는 Open API·더미 데이터로 구성한다. 기업별 담당자 관리, tenant_id 기반 데이터 격리, 테넌트 간 권한 검증은 MVP 구현 범위에서 제외한다. 공고의 회사명·회사 소개는 공고 컬럼(비즈니스 데이터)으로 유지한다.

유지하는 것: 지원자와 관리자의 역할 분리, 모든 API에서 역할과 데이터 소유권 서버 검증(지원자는 다른 지원자의 개인정보·이력서·답변·평가 보고서·코딩테스트 결과에 접근 불가), 개인정보 동의, 감사 로그, 데이터 보관·삭제 정책. 멀티테넌시 추상화(tenant_id 컬럼, 테넌트 미들웨어, 테넌트별 스키마)는 도입하지 않는다.

PRD v1.1과 충돌한 항목과 처리

PRD v1.1	충돌 내용	PRD v1.2 처리	TRD 영향
3장 주체와 역할 · 페르소나	'기업 담당자'(회사 소속, 여러 명)와 문서 밖 '운영자'가 따로 있음	둘을 '관리자' 1개 계정으로 통합, 운영 업무 포함	users.role = applicant / admin
ACC-03	기업 담당자 계정 사전 발급(회사별 여러 계정)	관리자 계정 1개, 설치 시 생성(시드)	관리자 생성 CLI, 초기 비밀번호 변경 강제
ACC-06	"담당자는 소속 기업 데이터만" 기업 범위 검증	지원자 본인 데이터 소유권 검증만, 관리자는 전체 조회	기업 범위 검사 삭제, 소유권 검사 의존성(11장)
AC-01	"A사 담당자는 B사 데이터를 볼 수 없다"	"지원자는 다른 지원자 데이터를 볼 수 없다, 관리자 API 거부"	13-1 테스트 변경
ADM-05	메모는 같은 기업 담당자만 열람	관리자만 열람	memos 기업 범위 삭제

APP-03 ③	"지원 기업에 결과 제공"	"공고를 운영하는 관리자에게 결과 제공"	동의 문구 버전 갱신
JOB-01 · 신설 JOB-08	공고는 회사 계정에 속함, 공고 출처는 직접 작성뿐	회사명·소개는 공고 내용으로만, Open API·더미 데이터 적재 추가	job_postings에서 company_id 삭제, company_name·company_intro·source 추가, 적재 작업(5-1)
10-1 · 10-3 보안	"기업 담당자 계정 사전 발급", "기업 범위 검증"	단일 관리자 제약 추가, 데이터 소유권 검증으로 변경	11장
2-2 비목표 · 11장	담당자 초대·권한 구분이 향후 검토	N8 멀티테넌시 제외, 실제 기업 계정은 향후 확장	1-4 확장 지점

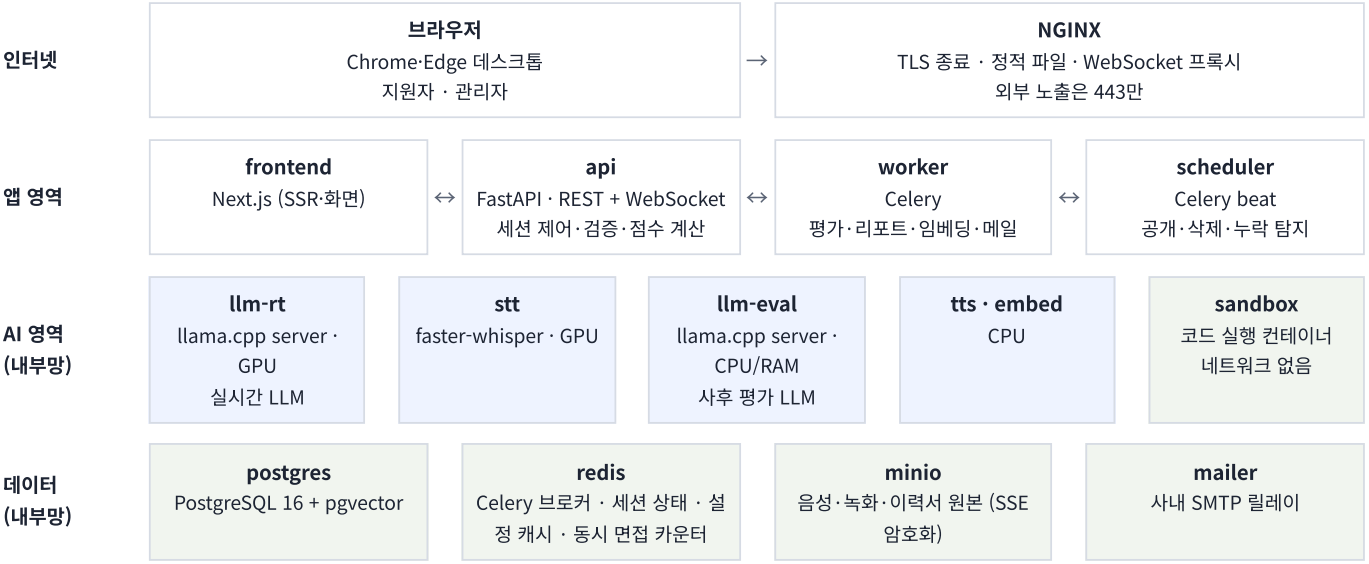
1-4. 확장 지점 (기록만, 미구현)

추후 실제 기업 계정을 지원할 때 손댈 곳을 적어 둔다. 지금은 아무것도 미리 만들지 않는다.

지점	지금 구조	확장 시 변경
계정·역할	users.role = applicant / admin	companies 테이블과 users.company_id 추가, role에 recruiter 추가
공고 소유	job_postings.company_name·company_intro (문자열)	job_postings.company_id 외래키로 바꾸고 기존 문자열을 companies로 이관
권한 검사	관리자 API는 `require_admin`, 지원자 API는 `require_owner` 의존성 한 곳에서 처리	`require_admin` 자리에 기업 범위 검사를 추가하면 라우터 수정 없이 적용 가능
설정	app_settings 전역 1벌	기업별 설정이 필요하면 키에 company_id 범위 추가
통계·알림	전체 기준 집계, 관리자 1명에게 알림	기업별 집계·수신자 분리

2. 시스템 아키텍처

2-1. 구성도



모든 서비스는 docker compose 하나로 띄운다. 외부에서 접근 가능한 컨테이너는 nginx뿐이며, AI·데이터 영역은 내부 네트워크(`internal: true`)에만 연결한다. 쿠버네티스·별도 모니터링 스택·부하 테스트 도구는 쓰지 않는다(팀 결정 10/20~10/21).

2-2. 서비스 책임

서비스	책임	주요 PRD

frontend	화면, 장치 점검(getUserMedia·AudioContext), 전체 화면·이탈 감지 (visibilitychange·blur·fullscreenchange), 녹음·녹화 청크 업로드, heartbeat 송신	APP-06~07, INT-01~05, CHT-01
api	인증·권한, 공고·기준 CRUD와 잠금, 응시 상태 머신, 질문 구성, 실시간 LLM·STT 호출, 동시 면접 입장 제어, 장애·이탈 판정, 점수 계산, 판정 검증, 결과 조회	대부분
worker	답변별 선평가, 최종 평가·AI 판정, 리포트·피드백 생성, 이력서 추출(OCR 포함), 임베딩, 코드 채점, 메일 발송	EVL, RPT, APP-04, COD-05
scheduler	결과 일괄 공개(매일 10:00), 보관 만료 삭제(매일), 누락·정체 작업 재등록(5분), 공고 자동 마감, 리마인더·만료 알림	RPT-02, 10-2, 10-3, JOB-01, ADM-08

3. 기술 스택

영역	선택	비고
프론트엔드	Next.js (App Router) · React · TypeScript, 코드 편집기 Monaco Editor	팀 확정(10/22)
백엔드	Python 3.11 · FastAPI · Pydantic v2 · SQLAlchemy 2 · Alembic	팀 확정(10/22)
비동기 작업	Celery + Redis 7 (브로커·결과), Celery beat	
DB	PostgreSQL 16 + pgvector (질문 임베딩 검색)	단일 DB
파일 저장	MinIO (S3 호환, 서버 측 암호화)	로컬 볼륨으로 대체 가능
LLM 서빙	llama.cpp server (GGUF, OpenAI 호환 API, `--parallel` 슬롯, GPU/CPU 레이어 분할)	VRAM 6GB에서 GPU·RAM 분할 적재가 가능해 vLLM 대신 선택
LLM	Qwen3 계열 GGUF 양자화 모델. 실시간용·평가용 구성은 6장	사고 모드 끔(`/no_think`)
STT	faster-whisper + Whisper Large V3 Turbo (CTranslate2, int8_float16)	한국어 고정
TTS	온프레미스 한국어 TTS, CPU 실행 (후보: Supertonic). 한국어 품질 확인 후 확정	실패 시 자막만(INT-01)
임베딩	BGE-M3 (sentence-transformers, CPU)	질문 은행 검색·중복 제거
이력서 추출	pdfplumber로 텍스트 추출 → 글자가 없으면 pypdfium2로 쪽 이미지 변환 → OCR → 평가용 LLM으로 구조화	APP-04, 7-6
OCR	PaddleOCR (한국어 인식 모델, CPU 실행). 대안: Tesseract kor	피드백 ⑥ GPU를 쓰지 않음. 7-6
코드 실행	Docker 격리 컨테이너 (python:3.11-slim, 네트워크 없음)	9장
프록시·배포	NGINX, docker compose	CI/CD·모니터링 스택 제외

라이브러리 세부 버전은 첫 구현 시 lock 파일(requirements.lock, package-lock.json)로 고정하고 이 표에 적는다.

4. 데이터 설계

4-1. 주요 테이블

테이블	주요 컬럼	PRD
users	id, role(applicant/admin — 관리자는 1명), email(unique), password_hash(Argon2id), name, phone, is_over_14, email_verified_at(nullable), must_change_password, failed_login_count, locked_until, deleted_at	ACC-01~06
job_postings	id, title, company_name, company_intro, source(manual/open_api/dummy), external_id(nullable, 중복 적재 방지), job_code('AI_AX' 고정, 준비 중 직무는 job_codes 테이블에 status='preparing'), 본문 필드, headcount, open_at, close_at, status(draft/published/closed), result_release_at	JOB-01, 2-4
evaluation_criteria	id, posting_id, version, weights(jsonb, 5항목), coding_enabled, coding_ratio, pass_score, locked_at	JOB-03~07
applications	id, posting_id, applicant_id(unique per posting), resume_snapshot(jsonb), resume_file_key, resume_extract_method(text/ocr/manual), ocr_confidence, ocr_low_conf_fields(jsonb), consent_id, attempt_status, analysis_status, result_status, release_status, attempt_consumed_at, release_at, purge_at(건별 공개일·삭제 예정일, 10장)	APP-02, 6-2
consents	id, user_id, application_id, text_version, items(jsonb), agreed_at, withdrawn_at	APP-03

questions	id, source(db/generated/reserve), category, sheet, text, is_coding, duplicate_group, embedding vector(1024), use_count, answer_seconds, eval_items	QST-01~02
interview_questions	id, application_id, seq, question_id, text_snapshot, kind(base/follow_up), parent_seq, generation_attempts, fallback_used, fallback_reason	QST-03, QST-05
answers	id, interview_question_id, audio_key, transcript, started_at, ended_at, stt_retries, is_empty	INT-04
item_scores	id, answer_id, eval_item, score(0~5), quote, quote_verified, regenerated	EVL-01~02
coding_submissions	id, application_id, problem_id, code, autosaved_at, submitted_at, passed, total, paste_attempts	COD-01~07
results	id, application_id, criteria_version, item_points(jsonb), interview_score, coding_score, total_score, ai_decision(pass/fail), ai_reason, ai_reason_quotes(jsonb), decision_check(ok/rejudged/needs_review), model_version, prompt_version, rubric_version, decided_at, public_view(jsonb)	EVL-03~06, RPT-01~04
session_events	id, application_id, type(heartbeat_miss/ws_close/offline/device/upload/server/unload/permission/visibility/blur/fullscreen), at, detail(jsonb), judgement	RES, CHT
memos · notifications · audit_logs · deletion_logs	메모(관리자 전용), 알림 큐, 감사 로그(식별자·시각·행위만), 삭제 기록	ADM-05, ADM-08, 10-2
app_settings	key, value(jsonb), updated_by, updated_at. 키 목록과 기본값은 14장 설정값 표	INT-08, QST-05, ACC-02

4-2. 저장 원칙

- 질문 스냅샷, 이력서 스냅샷, 적용 기준 버전은 응시 시점 값을 복사해 두고 이후 원본이 바뀌어도 바꾸지 않는다(QST-03, APP-05, JOB-07).
- 개인정보 컬럼(phone, 이력서 스냅샷)과 MinIO 객체는 AES-256으로 암호화한다(11장).
- 보관 만료 삭제는 행 삭제 + MinIO 객체 삭제 + 파생 데이터(임베딩·캐시·Redis 키) 삭제를 한 작업으로 수행하고 deletion_logs에 남긴다.

5. API·실시간 인터페이스

5-1. REST (주요)

메서드 · 경로	역할	PRD
POST /auth/signup · /auth/login · /auth/password-reset	가입·로그인·재설정. 이메일 인증 기능은 `email_verification_required` 가 true일 때만 지원 API에서 확인	ACC-01~05
GET /postings · /postings/{id}	공개 공고 목록·상세(로그인 불필요)	APP-01
POST /postings · PATCH /postings/{id} · POST /postings/{id}/publish · /close	관리자 공고 관리(`/admin` 하위, require_admin). 기준 잠금 후 기준 필드 변경은 409	JOB-01~07
POST /admin/postings/import	Open API 또는 더미 JSON/CSV에서 공고 적재. external_id로 중복 방지, status=draft로 저장. Open API 호출은 api 컨테이너에서만 나가며 공고 정보만 가져온다	JOB-08
POST /postings/{id}/draft-ai	AI 공고 초안 생성(평가용 LLM, 비동기)	JOB-02
POST /applications · /applications/{id}/consent · /resume	지원·동의·이력서 제출(추출은 worker)	APP-02~05
POST /applications/{id}/precheck	네트워크·AI 서버 상태 점검 결과 반환	APP-06
POST /applications/{id}/interview/start	입장 제어(5-3) 통과 시 세션 토큰 발급. 초과 시 429 + 안내 코드, 응시 횟수 미차감	INT-08
POST /interview/{sid}/answers/{seq}/audio	답변 음성 업로드(청크), STT 큐 등록	INT-04
POST /coding/{sid}/run · /autosave · /submit	공개 예제 실행, 30초 자동 저장, 최종 제출	COD-03~04
GET /me/results/{application_id}	공개 이후에만 public_view 반환, 그 전에는 404	RPT-03~04
GET /admin/postings/{id}/applicants · /applicants/{aid} · /compare	관리자 결과 조회(읽기 전용). 판정 수정·승인 엔드포인트 없음	ADM-01~04, EVL-05
POST /admin/applicants/{aid}/memo	내부 메모	ADM-05
PUT /admin/settings/{key}	관리자 설정 변경(N 등). 감사 로그 기록	INT-08
POST /admin/analysis/{aid}/reprocess	'확인 필요' 건 재처리	EVL-08

5-2. WebSocket `/ws/interview/{sid}`

방향	이벤트	내용
서버→클라이언트	question	seq, kind, 자막 텍스트, TTS 음성 URL(없으면 null), 답변 시간, 진행 표시('3 / 10')
클라이언트→서버	heartbeat	5초 주기. 서버는 3회 연속 누락(15초) 시 장애 후보로 기록
클라이언트→서버	answer_done · unload · visibility · blur · fullscreen · device_error	답변 완료, 사용자 종료 조작(beforeunload·pagehide), 이탈 신호, 장치 오류
서버→클라이언트	warn · terminate · paused · resume	1회차 경고, 2회차 강제 퇴장, 장애 중단 안내, 이어가기 재개

5-3. 동시 면접 입장 제어 (INT-08, 피드백 ⑤)

- Redis 카운터 `interview:active` 와 설정 `max_concurrent_interviews` (N)를 원자적으로 비교·증가(Lua 스크립트)한다. 면접 종료·취소·장애 중단 후 이어가기 기한(공고 마감 시각) 도달 시 감소한다. 장애 중단 중인 세션은 자리를 유지하므로 재접속(이어가기)은 N 검사 없이 들어온다.
- 추천안 **N에 세는 상태**: '면접 진행 중'과 그 상태에서 생긴 '장애 중단'만 센다. AI 면접 마지막 문항이 끝나 '코딩테스트 진행 중'으로 넘어가면 카운터를 반납한다(코딩테스트는 GPU를 쓰지 않음). 코딩테스트 중 장애 후 재접속도 N과 무관하다.
- 추천안 **초과 시**: start는 429와 안내 코드 `CAPACITY_FULL` 을 돌려주고, 화면은 안내 + '다시 시도' 버튼을 보여 준다. 서버 쪽 대기열·자동 입장은 없다. '다시 시도'는 같은 start를 다시 호출하며, 버튼은 10초 동안 비활성화해 연타를 막는다.
- N은 `PUT /admin/settings/max_concurrent_interviews` 로 바꾸며, 다음 입장 요청부터 즉시 적용된다(재시작 불필요). 낮추더라도 진행 중 면접은 끊지 않는다.
- 자원 보호(자동 조정): 30초마다 GPU 메모리 사용률(nvidia-smi/NVML)과 최근 5분 '답변 종료 → 다음 질문' p95를 확인해, VRAM 사용률 92% 이상 또는 p95 5초 초과가 이어지면 신규 입장만 일시 중지하고, 정상화되면 다시 연다. 실제 상한 = min(N, 자원 보호 상태).
- 초기 N은 13-2 벤치마크에서 p95 5초를 지키는 최대 동시 세션 수로 정한다.

6. 운영 장비와 AI 모델 배치

6-1. 운영 장비 (피드백 ③)

항목	값	설계 영향
GPU 전용 메모리	6GB (고정)	실시간 경로 모델만 GPU에 올린다. 공유 메모리로 넘치면 크게 느려지므로 GPU 적재 총량을 약 5.4GB 이하로 관리한다
시스템 RAM	58GB	사후 평가 LLM(CPU 추론), 임베딩, TTS, DB·Redis·MinIO를 RAM에서 처리할 여유가 있다
대수	서버 1대	모든 컨테이너를 한 장비에서 docker compose로 실행. 개발은 팀원 각자 환경, 최종 테스트는 이 장비

6-2. 모델 배치 기본안

용도	모델 · 형식	위치	메모리(추정)	호출 시점
실시간 LLM: 질문 맥락화·범위 조정·이력서 기반 질문·꼬리질문 판단	Qwen3-4B Instruct, GGUF Q4_K_M	GPU 전체 레이어	가중치 약 2.5GB + KV 캐시(슬롯당 4k 컨텍스트, q8_0 약 0.3GB)	면접 진행 중
STT	Whisper Large V3 Turbo, CTranslate2 int8_float16	GPU	약 1.0GB	답변 직후
평가 LLM: 루브릭 평가·AI 합불 판정·리포트·이력서 추출·공고 초안	Qwen3-8B Instruct, GGUF Q4_K_M	CPU/RAM (GPU 여유 시 일부 레이어만 GPU)	RAM 약 6~8GB	답변별 선평가(비동기), 응시 완료 후
임베딩	BGE-M3	CPU	RAM 약 2.5GB	질문 은행 적재 시, 질문 검색 시
OCR 피드백 ⑥	PaddleOCR 한국어 모델	CPU	RAM 약 1~2GB	이력서 업로드 시(면접 전, 비동기)
TTS	한국어 TTS (후보 Supertonic, ONNX)	CPU	RAM 1GB 미만	질문 제시 전 미리 합성

GPU 합계 목표: 실시간 LLM 2.5GB + KV(N 슬롯) + STT 1.0GB + CUDA 런타임 약 0.5GB ≤ 5.4GB. 이 식으로 N의 이론 상한이 대략 3~4로 나오며, 실제 N은 13-2 측정으로 정한다. 수치는 모델 파일 크기 기준 추정치다.

6-3. 왜 이렇게 나누는가

- PRD v1의 운영 기준(Qwen3-8B 양자화, VRAM 24GB급)은 6GB 장비에서 8B 모델 가중치(약 5GB)만으로 GPU가 거의 차서 STT와 KV 캐시를 함께 올릴 수 없다.
- 면접 중 응답 지연(다음 질문 p95 5초, 꼬리질문 판단 5초)은 GPU에서만 지킬 수 있으므로 실시간 경로는 더 작은 4B 모델을 GPU에 둔다.

- 평가와 판정은 PRD상 응시 완료 후 p90 10분 안에 끝나면 되고 답변마다 미리 평가(EVL-07)하므로, 품질이 더 높은 8B 모델을 58GB RAM에서 CPU로 돌린다.

6-4. 대안 (측정 결과에 따라 선택)

대안	내용	선택 조건
A. 기본안	실시간 4B(GPU) + 평가 8B(CPU)	8B CPU 평가가 응시 1건당 10분 안에 끝나고, 4B 꼬리질문 품질이 수용 가능할 때
B. 단일 4B	실시간·평가 모두 4B(GPU)	8B CPU 평가가 너무 느릴 때. 골든셋 일치도(PRD G2)를 다시 확인
C. 단일 8B	8B를 GPU에 올리고 STT는 CPU(int8)	4B 품질이 부족하고 N=1~2로 충분할 때. STT 지연 증가를 감수

7. 면접 세션·질문 구성·이력서 OCR

7-1. 응시 상태 머신

```
[마감 시각] 준비 중·대기 ─▶ 미응시(마감)  /  진행 중·장애 중단 ─▶ 응시 종료(마감, 답한 문항까지 평가)
준비 중 ─start(입장 제어 통과)─▶ 면접 진행 중 ─마지막 문항─▶ 코딩테스트 진행 중 ─submit/시간 종료─▶ 응시 완료
   │ 429(N 초과): 상태 유지, 횟수 미차감              │                          │
   │                                                ├─장애 판정 충족─▶ 장애 중단 ─재접속·재점검─▶ (직전 상태)
   │                                                ├─장애 기준 미충족(unload·권한 해제)─▶ 응시 종료
   │                                                └─이탈 2회─▶ 응시 취소(1차 불합격)
응시 횟수 차감: 첫 질문 제시 시점(attempt_consumed_at)
```

7-2. 장애 판정 구현 (RES, PRD 7-2)

- 서버는 세션별 마지막 heartbeat 시각을 Redis에 두고, 15초 초과 시 '장애 중단'으로 바꾸고 타이머를 멈춘다(남은 시간 저장).
- 판정은 직전 이벤트 로그로 한다. 연결 소실 직전 30초 안에 `unload`(beforeunload·pagehide) 또는 권한 해제 이벤트가 있으면 '미충족', 그 밖은 모두 '충족'(원인 불명 포함, 지원자에게 유리하게).
- WebSocket close code 1000/1001(정상 종료)은 unload 이벤트와 함께 있을 때만 사용자 종료로 본다.
- 재접속 시 환경 재점검 API를 다시 통과해야 하며, 끊긴 질문을 처음부터 새 답변 시간으로 다시 제시한다. 재개 기한은 공고 마감 시각까지(PRD INT-10).

유형별 감지 신호 v1.2 **(PRD v1.3 7-2 판정표에서 이관)**

PRD 유형	감지 신호	판정
네트워크 단절	heartbeat 3회 연속 누락(15초), WebSocket 비정상 종료(close code 1000·1001이 아니거나 unload 없이 1000·1001), 브라우저 `offline` 이벤트, 지원자 측 IP 변경으로 인한 재연결	충족
브라우저·기기 비정상 종료	직전 30초 안에 `unload` 이벤트 없이 연결 소실(브라우저 충돌, 기기 재시작, 배터리 방전, OS 강제 업데이트)	충족
장치 오류	MediaStreamTrack `ended`(장치 분리·드라이버 오류), 오디오 입력 레벨 10초 이상 0. `permission` 이벤트(지원자 권한 해제)가 함께 있으면 제외	충족
업로드 실패	답변 음성·코드 업로드 `upload_retry_limit`(3회) 실패	충족
서버·AI 장애	API 5xx, STT·TTS 서버 무응답, 음성 변환 `stt_retry_limit`(2회) 재시도 실패. 질문 생성 실패는 7-4 ⑤로 처리하며 장애가 아니다	충족
원인 불명	위 신호로 특정할 수 없음. 종료 조작 신호가 서버에 닿지 않은 경우(sendBeacon 실패 등)도 여기에 들어간다	충족(지원자에게 유리하게)
임의 종료	탭 닫기·새로고침·뒤로가기·주소 이동으로 `beforeunload`·`pagehide`가 `navigator.sendBeacon`으로 기록된 뒤 연결 소실	미충족
권한 해제	Permissions API `change` 이벤트로 마이크·카메라 권한이 denied로 바뀜	미충족

7-3. 화면 이탈 구현 (CHT)

- 클라이언트: `visibilitychange`(hidden), `blur` 후 `blur_threshold_sec`(2초) 이상 미복귀, `fullscreenchange`(해제), 주소 이동 시도를 이벤트로 보낸다. 서버가 횟수를 세고 면접·코딩테스트를 합산한다.
- 장애 판정 '충족'으로 처리된 구간 안의 이탈 이벤트는 세지 않는다. 2초 미만 blur는 클라이언트에서 버린다.
- 시선·얼굴 분석은 구현하지 않는다(CHT-06).

7-4. 질문 구성 파이프라인 (QST-01~05)

단계	처리

① 적재 v1.2	IT직무·인성 엑셀을 질문 은행에 적재하고 BGE-M3 임베딩을 만든다. **적재 명세(PRD v1.3에서 이관)**: IT직무_면접질문.xlsx는 32개 시트(기업_ 18개 6,577행, 생성_ 13개 137행, 빈 샘플 시트 1개 제외). 직무 카테고리는 머신러닝·딥러닝·컴퓨터 비전·데이터 사이언스·파이썬 계열 시트만 쓰고 나머지 시트는 준비 중 직무용으로 적재만 한다(status='preparing'). 인성_면접질문.xlsx는 448문항·21개 카테고리이며, 지원동기·동기/지원 이유·조직 문화 적합성 카테고리는 '기업 관련', 그 밖은 '인성'으로 매핑한다. '다른 중복 시트' 값으로 duplicate_group을 채우고, 코딩문제여부 '예'와 질문 텍스트가 빈 행은 구두 면접 후보에서 뺀다. 두 파일에 없는 answer_seconds(90)와 eval_items(PRD 5-7 카테고리별 평가 항목)는 적재 시 부여한다. 적재는 `manage.py load_questions`로 하며 같은 파일을 다시 넣어도 (sheet, 행 번호) 키로 중복되지 않는다
② 후보 검색 v1.2	카테고리별 조건(PRD 5-5 표)으로 후보를 뽑고 **같은 공고 안의 사용 횟수**(posting별 use_count) 오름차순으로 정렬한다. 동률은 application_id를 시드로 한 무작위 순서로 정해 재현 가능하게 한다. 한 면접 안에서 같은 duplicate_group과 임베딩 코사인 유사도 0.9 이상인 질문은 한 번만 쓴다. use_count는 질문 스냅샷이 확정될 때 1 올린다(응시하지 않은 구성분은 삭제 시 되돌림)
③ 생성·맥락화	이력서 기반 2문항은 실시간 LLM이 이력서 스냅샷으로 생성, 기업 관련 2문항은 공고 본문으로 표현만 맥락화. 후보 부족 시 같은 카테고리 질문 생성(QST-02)
④ 범위 검증	LLM이 {purpose, task_count, fits_time, revised_text} JSON을 낸다. task_count가 답변 시간 기준(90초 = 2개 이하)을 넘으면 revised_text로 바꾼다(QST-04)
⑤ 실패 처리 (피드백 ④)	JSON 스키마 오류, 검증 미통과(이력서에 없는 내용 등), 8초 타임아웃은 실패로 보고 같은 입력으로 최대 `question_regen_limit`(기본 3)회 재생성한다. 횟수는 슬롯마다 따로 세며, 지원자 1명의 질문 구성 전체에 `question_compose_budget_sec`(기본 60초) 상한을 둔다. 상한에 도달하면 진행 중인 시도를 끊고, 남은 슬롯은 LLM을 부르지 않고 바로 대체한다. 모두 실패하면 ② 후보 중 검증 통과한 DB 질문으로, 그것도 없으면 카테고리별 예비 질문(source='reserve', 관리자가 사전 검증)으로 대체한다. 이력서 기반 슬롯은 DB 카테고리가 없어 바로 예비 질문 '경험·프로젝트' 카테고리에서 고른다. generation_attempts·fallback_used·fallback_reason을 기록하고 장애 판정에는 넣지 않는다
⑥ 사전 준비 (구성 시점)	이력서 확정 이벤트에서 worker 큐 'compose'(낮은 우선순위)에 질문 구성 작업을 등록한다. 실시간 LLM 호출은 진행 중 면접 요청을 먼저 처리하도록 llama.cpp 슬롯을 면접용과 구성용으로 나눈다(구성용 1슬롯). ②~⑤를 마치면 10문항을 interview_questions에 저장하고 TTS를 미리 합성한다. start 시 구성 미완료면 '질문 준비 중' 상태로 대기 후 시작하며, 60초 상한(⑤)을 넘지 않는다. 응시 횟수는 첫 질문 제시 시점에 차감하므로 구성만 하고 응시하지 않으면 차감되지 않는다. 미사용 구성분은 응시 데이터 보관 규칙대로 삭제한다

7-5. 답변 처리와 꼬리질문 (INT-04, INT-06~07)

- 답변 음성은 청크 업로드 → 종료 시 faster-whisper(language='ko', VAD 필터) 변환. 실패 시 2회 재시도 후 장애 처리.
- 빈 답변 판정: 변환 결과가 비었거나 '모르겠습니다'류 패턴이면 꼬리질문 없이 다음 문항(INT-07).
- 꼬리질문 판단은 실시간 LLM에 5초 타임아웃으로 호출해 {need, reason_code, question} JSON을 받는다. 시간 초과·형식 오류면 생략. 질문당 1개, 면접 전체 4개 카운터는 서버가 관리한다.

7-6. 이력서 추출과 OCR (APP-04, 피드백 ⑥)

단계	처리
① 업로드 검사	PDF·JPG·PNG, 사용자 안내 상한 없음. 확장자와 파일 시그니처를 함께 확인한다. 서버 보호용 요청 크기 한도는 설정값 `upload_max_mb`(NGINX·API 공통, 사용자에게는 노출하지 않음)로만 둔다. 업로드 직후 예상 처리 시간 = 텍스트 쪽 수 × 0.5초 + 스캔 쪽 수 × 쪽당 OCR 시간(13-2에서 측정, 초기값 8초) + LLM 구조화 20초를 계산해 화면에 보여 준다. 원본은 MinIO에 암호화 저장
② 텍스트 우선	PDF는 pdfplumber로 쪽별 텍스트를 뽑는다. 쪽당 의미 있는 글자가 50자 미만이면 그 쪽은 스캔 쪽으로 보고 ③으로 보낸다
③ OCR	스캔 쪽과 이미지 파일을 pypdfium2/Pillow로 300dpi 이미지로 만들고 기울기 보정 후 PaddleOCR(한국어 모델, CPU)로 글자와 줄 단위 신뢰도를 얻는다. worker 큐 'ocr'에서 비동기 처리한다. 처리 시간이 예상 시간의 2배(최소 60초)를 넘거나, 추출 글자가 없거나, 전체 평균 신뢰도가 0.5 미만이면 실패로 보고 "불러오기 실패 — 직접 입력으로 진행할까요?" 응답을 돌려준다
④ 구조화	추출 텍스트를 평가 LLM에 넣어 학력·경력·프로젝트·기술·자격 JSON으로 만든다. OCR 줄 신뢰도 0.80 미만에서 나온 필드는 ocr_low_conf_fields에 넣어 화면에서 강조한다
⑤ 확인·수정	지원자가 결과를 확인·수정하고 확정하면 resume_snapshot으로 저장한다(APP-05). OCR 실패·글자 없음이면 직접 작성 화면으로 보낸다
⑥ 보관·삭제	OCR 중간 이미지는 처리 직후 삭제한다. 추출 텍스트와 원본은 응시 데이터로 보아 공개일 + 7일에 삭제한다(PRD 10-2)

OCR은 면접 시작 전에 끝나므로 면접 중 GPU 메모리에 영향을 주지 않는다. OCR 모델 파일도 내부 저장소에서 배포한다(외부 전송 0건).

8. 평가·1차 합불 판정 파이프라인 (피드백 ①)

8-1. 흐름

① 답변별 선평가 평가 LLM · 항목별 0~5점 + 인용 → **② 인용·형식 검증** 불일치 1회 재생성 → 실패 시 1점 → **③ 점수 계산** 항목 점수 · AI 면접 점수 · 종합 총점 → **④ AI 합불 판정** 판정 + 사유 + 근거 인용 → **⑤ 판정 검증** 기준 일관성 · 인용 · 스키마 → **⑥ 확정 · 리포트** 수정 불가

8-2. 단계별 구현

단계	구현	PRD
① 선평가	답변이 확정될 때마다 worker가 평가 LLM을 호출한다. 입력: 질문 스냅샷, 답변 텍스트(꼬리질문 답변 합침), 해당 평가 항목 정의와 루브릭, 이력서 스냅샷 요약. 이름·연락처·음성 특징은 넣지 않는다. 출력 JSON: `{items:[{item, score, quote}]}`. llama.cpp의 JSON 스키마 제약(grammar)으로 형식을 강제한다	EVL-01, EVL-07
② 검증	score가 0~5 정수인지, quote가 답변 원문의 부분 문자열인지(공백 정규화 후) 확인. 불일치 시 1회 재생성, 다시 실패하거나 답변은 있는데 근거가 없으면 1점, 미응답은 0점	EVL-02
③ 계산	항목 점수 = 해당 문항 점수 평균 ÷ 5 × 100, AI 면접 점수 = Σ(항목 점수 × 가중치), 종합 총점 = 반영 비중 합산(코딩테스트 미사용 시 AI 면접 점수). Decimal, 소수 둘째 자리 반올림	EVL-03~04
④ AI 판정	평가 LLM에 항목 점수·종합 총점·합격 기준·항목별 근거 인용을 주고 `{decision:"pass"|"fail", reason, quotes[]}` 를 받는다. 프롬프트에 '합격 기준과 총점을 비교해 판정하고, 사유는 근거 인용으로 설명'을 명시한다	EVL-05
⑤ 판정 검증	(a) decision이 '총점 ≥ 합격 기준' 비교와 같은지 (b) quotes가 원문과 일치하는지 (c) 스키마. 하나라도 어긋나면 1회 재판정, 다시 어긋나면 analysis_status='needs_review'로 관리자에게 알리고 재처리(EVL-08). 검증을 통과한 판정만 확정한다	EVL-05, AC-13
⑥ 확정	results에 판정·사유·점수 구성·적용 기준 버전·모델·프롬프트·루브릭 버전을 저장하고, 관리자용 리포트와 지원자 공개용 public_view(합불·강점·개선점·상태)를 따로 만든다	EVL-06, RPT-01~04

8-3. 실패·지연 처리

- Celery 작업은 멱등 키(application_id + 단계)로 중복 결과를 막는다. 실패 시 지수 백오프로 최대 3회 재시도, 30분 초과 또는 3회 실패 시 'needs_review'.
- 5분마다 '응시 완료인데 분석 작업이 없거나 정체된' 건을 찾아 다시 등록한다(AC-17).
- 부정행위 취소 건은 평가를 건너뛰고 decision='fail', reason='응시 취소'로 확정한다.

8-4. 하이라이트 구간 산출 (ADM-04) v1.2

- 후보: 확정된 item_scores 중 4~5점(우수)과 1~2점(감점) 항목. 문항별로 가장 높은 점수 1개와 가장 낮은 점수 1개를 고르고, 응시 1건당 우수·감점 각 최대 3개를 점수 차가 큰 순으로 남긴다. 0점(미응답)은 구간이 없으므로 제외한다.
- 구간 위치: 인용(quote)을 STT 단어 타임스탬프(faster-whisper `word_timestamps=True`)와 맞춰 시작·끝 시각을 구하고 앞뒤 1초를 더한다. 인용 검증(8-2 ②)을 통과한 인용만 쓰므로 위치를 못 찾는 경우가 없다. 1점 확정(근거 없음) 항목은 그 답변 전체를 구간으로 한다.
- 저장: `highlights` (application_id, answer_id, kind(good/bad), eval_item, start_ms, end_ms, quote). 음성 원본과 같이 공개일 + 7일에 삭제한다.
- 관리자 화면은 답변 음성 타임라인 위에 구간을 표시하고 클릭하면 해당 시각부터 재생한다(MinIO 서명 URL, 5분 유효).

9. 코딩테스트 실행 환경 (COD)

항목	값
격리	요청마다 일회용 컨테이너(python:3.11-slim), `--network none`, 읽기 전용 루트 파일시스템, 비루트 사용자, `--pids-limit 64`

제한	문항당 실행 10초(벽시계), 메모리 256MB, CPU 1코어
채점	공개+비공개 테스트케이스 통과율 × 100, 2문항 동일 배점. 비공개 케이스와 정답은 sandbox 내부에만 마운트하고 API 응답·LLM 입력에 넣지 않는다
편집기	Monaco, 30초 자동 저장, 외부 붙여넣기 차단(paste 이벤트에서 편집기 내부 복사 버퍼와 비교), 시도 횟수 기록
시간	2문항 합계 60분, 서버 기준 타이머. 장애 중단 시간은 제외. 종료 시 마지막 저장 코드 자동 제출

10. 결과 공개·알림·배치 작업

작업	주기	내용	PRD
공통 v1.2	—	모든 예약 작업과 날짜 계산은 `Asia/Seoul` 기준. 지원 건마다 applications.release_at(공개 시각)과 purge_at(= release_at + 7일)을 저장해 일괄 공개 건과 지연 공개 건을 같은 방식으로 처리한다. 녹화 삭제 시각은 응시 종료 + 3일로 따로 계산한다	RPT-02, 10-2
결과 일괄 공개	매일 10:00	release_at이 지난 확정 결과를 release_status='public'으로 바꾸고 사이트 알림 + 이메일. 미산출 건은 산출 시 release_at = 다음 날 10:00으로 정해 개별 공개	RPT-02, EVL-08
보관 만료 삭제	매일 03:00	녹화: 응시 종료 + 3일, 응시 데이터: purge_at(공개일 + 7일) 경과 건. 원본·파생 데이터 삭제와 deletion_logs 기록	10-2, AC-18
누락 탐지	5분	정체·누락 분석 작업 재등록	10-3, AC-17
공고 마감 처리	close_at 정각	게시 시 close_at에 맞춘 예약 작업(Celery eta)을 등록하고, 5분 주기 점검으로 누락을 보정한다. 마감 시: 공고 status='closed', 준비 중·대기 응시 → 'not_taken_closed', 진행 중·장애 중단 세션 → WebSocket `terminate{reason:'closed'}` 전송 후 'ended_closed'로 바꾸고 평가 작업 등록. start·이어가기 API는 마감 후 409와 안내 코드 반환. 동시 면접 카운터 반납	JOB-01, INT-10
알림·리마인더	매시	마감 3일·1일 전 미완료 지원자, 마감 1일 전 관리자, 결과 열람 만료 2일 전 지원자(건별 purge_at 기준). v1.2 관리자 '보관 만료 2일 전' 알림은 건별 purge_at이 다르므로 **날짜별 묶음**으로 보낸다: 매일 09:00에 purge_at이 2일 뒤인 지원 건을 공고별로 모아 한 통으로 알린다	ADM-06, ADM-08, RPT-05
메일 발송 재시도	실패 시	Celery 작업 재시도 최대 3회(countdown 60초·300초·1800초). SMTP 4xx·연결 오류만 재시도, 5xx 영구 오류(주소 없음 등)는 바로 실패 처리. 최종 실패는 notifications.status='failed'·실패 사유 기록, 관리자 대시보드에 실패 건수 표시. 사이트 내 알림은 별도로 항상 생성	ADM-08
이메일 인증 (피드백 ②)	요청 시	후순위 기능. 구현 시 24시간 유효 토큰 메일 발송(재발송은 1분에 1회), email_verified_at 기록, 설정 `email_verification_required` =true로 지원 API에서 확인. 구현 전에는 false. 추천안 기능을 켤 때 기존 가입자: 진행 중인 지원(applications 존재 건)은 검사하지 않고, **새 지원 생성(POST /applications)에서만** email_verified_at을 확인해 미인증이면 403 + 인증 메일 재발송 안내	ACC-02

11. 보안·개인정보

영역	구현
전송	NGINX TLS 1.2 이상(1.3 우선), HSTS. 내부 서비스 간 통신은 내부 네트워크로 제한
로그인 복귀 경로 v1.2	ACC-04의 `next` 값은 '/'로 시작하고 '//'·'/\'로 시작하지 않으며 스킴·호스트가 없는 상대 경로만 받는다. 허용 접두어는 `/postings/` , `/applications/` , `/me` . 조건에 안 맞으면 `/me` 로 보낸다(오픈 리다이렉트 방지)
저장	MinIO SSE(AES-256), DB 민감 컬럼은 애플리케이션 계층 AES-256-GCM 암호화(키는 환경 변수가 아닌 별도 키 파일, 권한 600)
인증	비밀번호 규칙(PRD 5-1): 8~64자, 영문·숫자·특수문자 각 1자 이상, 이메일 아이디 포함 금지, 같은 문자 4번 이상 연속 금지. 가입·변경·재설정 API에서 서버가 검증. Argon2id 해시, 세션 쿠키(HttpOnly·Secure·SameSite=Lax), 마지막 요청 후 2시간 만료(면접 중 연장), 5회 실패 시 10분 잠금, 재설정 링크 30분
권한	단일 관리자 역할 + 데이터 소유권 검사. 관리자 API(`/admin/*`)는 `require_admin` , 지원자 API는 `require_owner` 로 모든 조회에 `applicant_id = 현재 사용자` 조건을 붙인다(이력서·답변·결과·코딩 제출·녹화 URL 포함). 다른 지원자 리소스 ID 요청은 존재 여부를 드러내지 않도록 404. 관리자 API의 결과 판정은 읽기 전용(메모·설정·재처리 제외). 테넌트 검사는 없다(1-3)
로그	모델·런타임 이미지는 내부 저장소에서 배포하고 태그·해시로 버전을 고정한다. 감사 로그: 결과 열람, 녹화 재생, 메모, 동의, 기준 변경, 설정 변경, 삭제, 장애·이탈 판정. 앱 로그에서 답변 원문·개인정보 마스킹
외부 전송 차단	AI·데이터 컨테이너는 외부 경로가 없는 내부 네트워크에만 연결해 외부 전송 0건(AC-19)을 구조로 보장. 모델 파일은 사전 내려받아 내부 저장소에서 마운트
공정성	평가 입력 생성 함수에서 인적 정보 필드를 제거하는 단위 테스트를 둔다. 이름·성별 단서만 바꾼 대조 테스트(±0.5점)를 출시 전 실행

12. 성능 목표와 측정

지표	목표	측정 방법
답변 종료 → 다음 질문 표시	p95 5초 이내	서버 이벤트 시각 차이(answer_done → question 송신)
꼬리질문 판단	5초 이내, 초과 시 생략	LLM 호출 타임아웃
일반 API	p95 300ms 이내	미들웨어 응답 시간 로그
결과 산출	응시 완료 → 확정 p90 10분 이내	completed_at → decided_at
STT 단어 오류율	10% 미만	한국어 면접 답변 샘플 30개 수작업 전사 대비
GPU 메모리	N 세션 동시 진행 시 5.4GB 이하, 공유 메모리 사용 0	NVML 기록
AI 점수 일치도	골든셋 가중 kappa 0.6 이상, ±1점 일치 80% 이상	카테고리별 30개 답변 · 전문가 2인 채점과 비교

13. 테스트 계획

13-1. 인수 기준 매핑

AC	테스트 방법
AC-01~05	API 통합 테스트: 비로그인 접근 401, 지원자 A 토큰으로 지원자 B의 이력서·답변·결과·코딩 제출 ID 요청 시 404, 지원자 토큰으로 /admin 호출 시 403, 가입 필드, 준비 중 직무 선택 거부, 2회차 응시 거부, 사전 조건 미완료 시 start 거부
AC-06~08	질문 구성 단위 테스트(10문항 구성·꼬리질문 상한), QST-04 시나리오 3종, 화면에 중단 버튼 없음(E2E)
AC-09~11	Playwright E2E: 네트워크 차단 → 15초 내 장애 중단 → 재접속 이어가기 반복, 탭 닫기 → 응시 종료, 탭 전환 1·2회

AC-12~17	평가 파이프라인 테스트: 인용 불일치·근거 없음 처리, 계산식 대조, AI 판정과 기준 불일치 주입 → 재판정·needs_review, 판정 수정 API 부재, 기준 잠금, 공개 전 비노출, 누락 탐지
AC-18~19	시간 이동(freezegun)으로 삭제 배치 검증, 내부 네트워크 외부 접속 시도 실패 확인
AC-20 (QST-05)	LLM 목(mock)으로 3회 연속 실패 주입 → DB 질문 대체, DB 후보 제거 → 예비 질문 대체, 기록 확인
AC-21 (INT-08)	N=1 설정 후 두 번째 start 429·횟수 미차감, 설정 변경 직후 반영 확인
AC-22 (APP-04)	스캔 PDF·사진 이력서 샘플 10종(기울어짐·저해상도 포함)으로 추출 결과와 신뢰도 표시 확인, 처리 중 외부 네트워크 호출 0건. 처리 시간 초과·저신뢰 샘플로 '불러오기 실패 → 직접 입력' 흐름 확인
AC-23 (INT-10) v1.2	freezegun으로 close_at을 넘겨 준비 중·대기·면접 진행 중·코딩테스트 진행 중·장애 중단 각 1건을 검증: 시작 전 건은 not_taken_closed와 start 409·버튼 비활성 문구, 진행 중 건은 WebSocket terminate{reason:'closed'} 후 ended_closed·평가 작업 등록·남은 문항 0점, 장애 중단 건은 이어가기 409, 동시 면접 카운터 반납

13-2. 운영 장비 벤치마크 (VRAM 6GB · RAM 58GB)

1. 모델별 단독 적재 메모리 측정: Qwen3-4B Q4_K_M(GPU), Whisper Turbo int8_float16(GPU), Qwen3-8B Q4_K_M(CPU).
2. 가상 지원자 스크립트로 동시 세션 1, 2, 3, 4…를 늘리며 '다음 질문' p95, 꼬리질문 판단 시간, VRAM을 기록한다. p95 5초와 VRAM 5.4GB를 지키는 최대값을 초기 N으로 정한다.
3. 응시 1건(10문항 + 꼬리질문 4개) 평가·판정을 8B CPU로 실행해 소요 시간을 잰다. 10분을 넘기면 6-4의 대안 B 또는 C로 전환한다.
4. 결과를 이 문서 6장과 app_settings 초기값에 반영하고 개정 이력에 남긴다.

14. 설정값 표 v1.2 신설

재시도 횟수·타임아웃·임계값·주기는 이 표 한 곳에서 관리하고 본문은 이 표를 참조한다. 값은 `app_settings` (재시작 없이 변경) 또는 환경 설정 파일로 둔다. **운영 장비** 열이 기준값이며, **개발 환경** 열은 팀원 각자 장비(작은 GPU·CPU만)에서 기능을 확인할 때만 쓰는 완화값이다. 최종 테스트와 인수 기준 확인은 운영 장비 값으로 한다(PRD 10-1).

키	운영 장비	개발 환경	의미	본문
면접 진행				
`max_concurrent_interviews`	2 (임시, 13-2로 확정)	1	동시 면접 상한 N	5-3
`admission_guard_vram_pct` · `admission_guard_p95_sec` · 점검 주기	92% · 5초 · 30초	끔	신규 입장 일시 중지 조건	5-3
`heartbeat_interval_sec` · `heartbeat_miss_limit`	5초 · 3회(15초)	같음	연결 이상 감지(PRD AC-09 15초)	5-2, 7-2
`unload_lookback_sec`	30초	같음	연결 소실 직전 종료 조작 확인 구간	7-2
`blur_threshold_sec`	2초	같음	이 시간 미만 포커스 이탈은 세지 않음	7-3
`upload_retry_limit`	3회 (1·2·4초 간격)	같음	답변 음성·코드 업로드 재시도, 초과 시 장애	7-2
`stt_retry_limit` · STT 시도 타임아웃	2회 · 20초	2회 · 60초	음성 변환 재시도, 초과 시 장애	7-5
`followup_timeout_sec`	5초 (PRD INT-06)	15초	꼬리질문 판단 상한, 초과 시 생략	7-5
질문 구성				
`question_regen_limit`	3회 (팀 결정)	같음	슬롯마다 재생성 상한	7-4 ⑤
`question_attempt_timeout_sec`	8초	30초	재생성 1회 시도 상한	7-4 ⑤
`question_compose_budget_sec`	60초 (팀 결정)	180초	지원자 1명 질문 구성 전체 상한	7-4 ⑤⑥
이력서·OCR				
`upload_max_mb`	50MB (사용자 비노출)	같음	서버 보호용 요청 크기 한도	7-6 ①
`ocr_sec_per_page`	8초 (13-2로 갱신)	측정값	예상 처리 시간 계산	7-6 ①
`ocr_fail_factor` · 최소	예상 시간의 2배 · 60초	같음	넘으면 불러오기 실패	7-6 ③
`ocr_fail_conf` · `ocr_low_conf`	0.5 · 0.80	같음	실패 기준 평균 신뢰도 · 강조 표시 기준	7-6 ③④
평가·판정				
`quote_regen_limit` · `rejudge_limit`	1회 · 1회	같음	인용 불일치 재생성 · 판정 불일치 재판정	8-2
`analysis_retry_limit` · 백오프	3회 · 1·2·4분	같음	분석 작업 재시도	8-3
`needs_review_after_min`	30분	120분	이 시간 넘으면 '확인 필요'	8-3

`stuck_scan_interval_min`	5분	같음	누락·정체 작업 재등록 주기	8-3, 10장
코딩테스트				
실행 시간 · 메모리 · CPU · 프로세스	10초 · 256MB · 1코어 · 64	같음	문항당 샌드박스 제한(문제 화면에 표시)	9장
자동 저장	30초 (PRD COD-03)	같음		9장
계정·보안				
세션 · 로그인 잠금 · 재설정 링크	2시간(면접 중 연장) · 5회/10분 · 30분 (PRD ACC)	같음		11장
`email_verification_required`	false (기능 추가 후 true)	false	이메일 인증 요구	10장
배치·알림				
`timezone`	Asia/Seoul	같음	모든 예약 작업과 공개·삭제일 계산 기준	10장
결과 공개 · 보관 만료 삭제	매일 10:00 · 매일 03:00	수동 실행		10장
`mail_retry_limit` · 간격	3회 · 60·300·1800초	같음	메일 발송 재시도	10장

개발 환경 값은 `.env.dev` 에만 두고 운영 설정 파일과 섞지 않는다. 운영 장비 값을 바꾸면 이 표와 개정 이력을 함께 고친다.

15. 확인 필요 사항

#	항목	현재 기본값	확정 방법
T-01	모델 배치 (실시간 4B GPU + 평가 8B CPU)	6-2 기본안	13-2 벤치마크
T-02	동시 면접 상한 N 초기값	2 (임시)	13-2 벤치마크
T-03	한국어 TTS 엔진	Supertonic 후보	한국어 음질·속도 확인, 불가 시 다른 온프레미스 엔진
T-04	AI 판정이 기준 비교와 어긋나는 빈도	1회 재판정 후 needs_review	골든셋으로 불일치율 측정, 잦으면 프롬프트 조정
T-05	예비 질문 세트	카테고리별 5문항 이상(이력서 슬롯용 '경험·프로젝트' 카테고리 포함)	관리자가 사전 검증해 적재
T-06	OCR 엔진과 인식 품질	PaddleOCR 한국어, 신뢰도 기준 0.80	한국어 이력서 샘플로 글자 정확도·처리 시간 측정, 부족하면 Tesseract kor 비교
T-07	추천안 3건 (PRD v1.3 v1.3 추천안)	코딩테스트 단계 N 제외·'다시 시도'(5-3), 이메일 인증 도입 시 새 지원부터 요구(10장)	팀 확인
T-08	공고 차별 소지 표현 감지 (JOB-02, 팀원 미결 O-05)	미정 (추천: 규칙 기반 사전, 경고만)	팀 결정 후 5-1 draft-ai와 공고 편집 화면에 반영

부록. PRD 요구사항 추적표

PRD	TRD 위치	변경 (PRD v1.2 · v1.3)
ACC-01~06 (계정·가입)	4-1 users, 5-1, 10장 이메일 인증, 11장 인증·권한	ACC-01·03·06 단일 관리자 · 소유권 검증 (1-3). v1.3: ACC-04 복귀 경로 검증 이관(11장), ACC-02 기존 가입자 추천안(10장)

JOB-01~08 (공고·평가 기준)	4-1 job_postings·evaluation_criteria, 5-1	JOB-01 회사 정보는 공고 컬럼, JOB-08 공고 적재 신설
APP-01~07 (지원·사전 준비)	4-1 applications·consents, 5-1, 2-2 frontend, 7-6 이력서 추출·OCR	APP-03 ③ 결과 제공 대상 = 관리자, ② 설명 요구권 안내 삭제. APP-04 용량 상한 없음·예상 처리 시간·실패 시 직접 입력(7-6)
INT-01~10 (AI 면접)	5-2, 5-3, 7-1, 7-5, 10장 마감 처리, 14장	INT-10 마감 시 중단 신설. v1.3: INT-04 재시도 횟수 이관, INT-08 코딩테스트 제외·다시 시도 추천안
QST-01~05 (질문)	7-4	QST-03 구성 시점, QST-05 슬롯별 3회·60초·대체 질문. v1.3: QST-01 선정 규칙·5-5 적재 명세·QST-04 구현 방향 이관(7-4)
COD-01~07 (코딩테스트)	9장, 14장	v1.3: COD-05 제한값 이관
EVL-01~08 (평가·판정)	8장, 14장	v1.3: EVL-02·05·08 재시도·재판정 횟수 이관, 관리자는 재처리만
RPT-01~05 (결과 공개)	8-2 ⑥, 10장	RPT-03 설명 요청 안내 삭제(N7)
ADM-01~08 (관리자 결과 관리)	5-1 /admin, 10장	ADM-05 메모 관리자 전용. v1.2: ADM-04 하이라이트 산출(8-4), ADM-06 만료 알림 날짜별 묶음(10장)
RES-01~06 (장애 이어가기)	7-1, 7-2	RES-03 재개 기한 = 마감 시각. v1.3: 7-2 감지 신호 열 이관
CHT-01~06 (화면 이탈)	7-3, 14장	v1.3: 감지 이벤트·2초 기준 이관
AC-01	13-1	타 기업 격리 → 지원자 간 소유권·관리자 API 거부
10-1~10-3 (가정·제약·비기능)	1-3, 6장, 11장, 12장	단일 관리자 제약 추가, 보안 소유권 검증. v1.3: 암호화 방식·모델 후보·작업 재등록 주기 이관, 개발/운영 값 분리(14장)
N7 · N8 (비목표)	1-3, 1-4	이의제기·설명 요청 제외, 멀티테넌시 제외(확장 지점만 기록)